

Esercizio 1: FRUTTA

I dati in analisi riguardano la produzione raccolta di 7 diverse coltivazioni legnose agrarie delle 20 regioni italiane. In particolare sono state rilevate le quantità di:

- uva da tavola raccolta (migliaia di quintali);
- uva da vino raccolta (migliaia di quintali);
- vino prodotto (migliaia di ettolitri);
- arance raccolte (migliaia di quintali);
- mandarini raccolti (migliaia di quintali);
- clementine raccolte (migliaia di quintali);
- limoni raccolti (migliaia di quintali).

Si prosegue nell'analisi con lo scopo di descrivere la produzione regionale italiana di coltivazioni legnose agrarie, individuando eventuali legami lineari tra le produzioni e similarità di comportamento fra le regioni.

Variabile	N	Media	Mediana	Range	Coeff di variazione	Minimo	Massimo
uvatavol	20	539.800	20.000	6031.000	261.131	0.000	6031.000
uvavino	20	3677.350	2364.500	10675.000	94.484	47.000	10722.000
vinoprod	20	2746.350	1618.500	8123.000	97.100	30.000	8153.000
arance	20	924.250	0.000	11468.000	289.315	0.000	11468.000
mandarin	20	104.350	0.000	1082.000	245.975	0.000	1082.000
clementine	20	129.650	0.000	1460.000	261.898	0.000	1460.000
limoni	20	331.700	0.000	5844.000	382.562	0.000	5844.000

Da una prima analisi descrittiva dei dati si osserva che la coltivazione maggiormente praticata in Italia è quella dell'uva da vino, caratterizzata da una produzione media di 3677.350 migliaia di quintali, seguita dalla produzione di vino (2746.350) e dalla raccolta di arance (924.250). In generale, tutte le coltivazioni presentano un valore medio di produzione più elevato del valore mediano: questo indica la presenza di quantità prodotte particolarmente elevate per alcune regioni che influenzano in eccesso il valore medio di produzione. Ciò è più evidente nelle produzioni di uva da tavola e degli agrumi: la prima è caratterizzata da una produzione media di quasi 540 migliaia di quintali contro le 20 migliaia di quintali di produzione mediana, dovuta alla presenza di outliers come la Puglia, a cui infatti corrisponde il massimo della produzione di uva da tavola, la Sicilia e l'Abruzzo; le coltivazioni di arance, mandarini, clementine e limoni presentano tutte una produzione mediana nulla rispetto a produzioni medie notevolmente più elevate (rispettivamente 924.250, 104.350, 129.650 e 331.700 migliaia di quintali), dovuta al fatto che più della metà delle regioni non producono quel determinato agrume, alcune di queste sono Lombardia, Piemonte, Valle d'Aosta, Trentino Alto Adige e Veneto che non producono alcun agrume.

Il confronto tra i coefficienti di variazione evidenzia una certa eterogeneità delle produzioni fra le diverse regioni italiane: esse si differenziano maggiormente per la coltivazione di limoni che presenta il valore più alto del coefficiente (382.562), mentre le produzioni di arance, mandarini, clementine e uva da tavola presentano una variabilità simile e lo stesso accade per la coltivazione di uva da vino e la produzione di vino, ciò significa che le quantità prodotte nelle varie regioni sono simili tra di loro.

Si osserva quindi che le produzioni di agrumi e di uva da tavola caratterizzano maggiormente le regioni del meridione, mentre la raccolta di uva da vino e la produzione di quest'ultimo interessano, seppur con intensità diverse, tutte le regioni italiane.

Coefficienti di correlazione di Pearson, N = 20							
	uvatavol	uvavino	vinoprod	arance	mandarin	clementine	limoni
uvatavol	1.00000	0.47973	0.50931	0.32362	0.35085	0.17268	0.35854
uvavino	0.47973	1.00000	0.99689	0.32020	0.30588	0.03575	0.40784
vinoprod	0.50931	0.99689	1.00000	0.32819	0.31299	0.04010	0.41646
arance	0.32362	0.32020	0.32819	1.00000	0.98860	0.72309	0.92533
mandarin	0.35085	0.30588	0.31299	0.98860	1.00000	0.74260	0.90353
clementine	0.17268	0.03575	0.04010	0.72309	0.74260	1.00000	0.40898
limoni	0.35854	0.40784	0.41646	0.92533	0.90353	0.40898	1.00000

Dall'analisi delle correlazioni fra le produzioni si osserva una quasi perfetta relazione lineare positiva tra la coltivazione di uva da vino e la produzione di vino, lo stesso accade per le produzioni di mandarini e arance, di limoni e mandarini, di limoni e arance. Ciò significa che per tutte queste coppie di produzioni, all'aumentare di una, in media l'altra cresce e viceversa. Lo stesso ragionamento, seppur in misura minore, è applicabile alla coltivazione di clementine con le produzioni di arance e mandarini, che infatti presentano un coefficiente di correlazione elevato intorno a 0.7: i valori di queste produzioni, mediamente, crescono e decrescono insieme. I legami lineari tra la produzione vinicola e la coltivazione di agrumi sono invece trascurabili, ovvero, data l'informazione su una delle due produzioni, non si può trarre alcuna conclusione sull'altra, ad eccezione del legame fra la coltivazione di limoni e la produzione di vino e fra la coltivazione di limoni e quella di uva da vino, corrispondenti a coefficienti leggermente superiori a 0.4. Infine si segnala una modesta correlazione fra la raccolta di uva da tavola e la raccolta di uva da vino e la produzione di quest'ultimo, identificata da valori pari a circa 0.5.

Vista la forte diversità tra le 7 produzioni, si procede con la standardizzazione dei dati in modo da uniformare, oltre che l'unità di misura delle quantità, la variabilità delle produzioni per una più appropriata applicazione delle successive metodologie.

Autovalori della matrice di correlazione: Totale = 7 Media = 1				
	Autovalore	Differenza	Proporzione	Cumulativa
1	3.99403545	2.15359640	0.5706	0.5706
2	1.84043905	1.19584393	0.2629	0.8335
3	0.64459512	0.13888913	0.0921	0.9256
4	0.50570599	0.49315338	0.0722	0.9978
5	0.01255261	0.01016072	0.0018	0.9996
6	0.00239190	0.00211203	0.0003	1.0000
7	0.00027987		0.0000	1.0000



Stime di comunanza finali: Totale = 6.479070						
uvatavol	uvavino	vinoprod	arance	mandarin	clementine	limoni
0.96823519	0.96592202	0.97084116	0.99333712	0.98889495	0.73366335	0.85817583

regione	contr3
Campania	0.56215
Calabria	0.75596
Sardegna	0.86500

Tramite un'analisi in componenti principali si costruiscono 3 indicatori che, non solo globalmente spiegano il 92,6% della variabilità totale, ma rappresentano in modo ottimale sia le produzioni che le regioni: le produzioni di uva da tavola, uva da vino, vino, arance e mandarini presentano communalities prossime al valore 1, che indicano una loro rappresentazione quasi perfetta, similmente, la quota di variabilità spiegata delle restanti produzioni di clementine e limoni è altrettanto elevata, superiore al 73%; dall'analisi delle contribuzioni relative, la regione che presenta il livello di rappresentatività più basso è la Campania (56%), seguita dalla Calabria (76%), caratterizzata da una bontà di rappresentazione comunque elevata, infine tutte le altre regioni presentano contribuzioni relative maggiori del 87% e sono quindi rappresentate in modo ottimale.


Pattern fattoriale ruotato			
	Factor1	Factor2	Factor3
uvatavol	0.17632	0.33505	0.90823
uvavino	0.12554	0.95678	0.18639
vinoprod	0.13049	0.95223	0.21695
arance	0.97223	0.20457	0.07907
mandarin	0.97079	0.17677	0.12333
clementine	0.80387	-0.20676	0.21142
limoni	0.84296	0.38385	0.01582

Si procede con una rotazione ortogonale delle componenti con il metodo varimax con lo scopo di ottenere indicatori più facilmente interpretabili. La prima componente presenta correlazioni elevate (superiori a 0.8) con le produzioni di arance, mandarini, clementine e limoni, contrapposte a bassi valori dei coefficienti di correlazione con le produzioni di uva da tavola, di uva da vino e di vino, pertanto può essere interpretato come un indicatore crescente della produzione di agrumi nelle regioni italiane. La seconda componente è invece indicatore crescente della produzione vinicola: il legame lineare è rilevante con la coltivazione di uva da vino e la produzione di vino stesso, caratterizzate da coefficienti di correlazione superiori a 0.95, mentre le altre correlazioni sono trascurabili. Infine la terza componente, che presenta una quasi perfetta relazione lineare positiva con la produzione di uva da tavola e correlazioni inferiori a 0.22 con le restanti produzioni, è indicatore crescente della quantità di uva prodotta e destinata alla tavola.




Dall'analisi dello scatter plot nel primo piano principale emerge che ~~il maggiore contributo al primo indicatore è dato~~ dalla regione Sicilia con uno score pari a 3.54, che quindi è la maggiore produttrice di agrumi, subito seguita dalla Calabria con uno score pari a 2.21. Per quanto riguarda la produzione vinicola, Emilia Romagna, Veneto e Sicilia presentano punteggi elevati del secondo indicatore, rispettivamente pari a 2.09, 2.06 e 1.77, pertanto queste regioni emergono come maggiori produttrici di vino. Nella seconda mappa si osserva un punteggio elevato del terzo indicatore corrispondente alla Puglia, con uno score di 4.13, che è la maggiore produttrice di uva da tavola d'Italia. Le regioni posizionate in prossimità dell'origine degli assi, come Abruzzo, Toscana, Marche e Lombardia in entrambe le mappe, sono in media, ovvero presentano produzioni vicine alle produzioni medie di agrumi, vino e uva da tavola.

Cronologia dei cluster							
Numero di cluster	Cluster uniti		Freq	R-quadro semiparziale	R-quadro	R-quadro atteso approssimato	Criterio di clusterizzazione cubica
5	CL8	CL6	15	0.0346	.943	.	.
4	CL14	Puglia	3	0.0913	.852	.743	3.53
3	CL5	Calabria	16	0.1748	.677	.655	0.49
2	CL3	CL4	19	0.2207	.457	.479	-.32
1	CL2	Sicilia	20	0.4566	.000	.000	0.00



Proseguendo con una cluster analysis gerarchica aggregativa con il metodo di Ward, si individua una partizione in 4 gruppi. La scelta è giustificata da un valore dell'indice ccc maggiore di 2 e, rispetto all'andamento dell'indice R quadro, da una brusca diminuzione del suo valore, da 0.852 a 0.677, in corrispondenza della partizione successiva in 3 gruppi: ciò conferma la bontà globale della partizione che infatti spiega più dell'85% della variabilità totale. La scelta della partizione in 4 gruppi è inoltre giustificata, localmente, dall'indice R quadro semiparziale: in corrispondenza della partizione in 3 gruppi si aggregano due gruppi diversi fra di loro in quanto si registra un peggioramento, in termini di coesione interna al gruppo, circa pari a 0.175 e perciò si preferisce tenere separati i due cluster interessati.



Dalla lettura del dendrogramma emerge che le prime regioni ad aggregarsi sono Umbria e Friuli Venezia Giulia, Lombardia e Marche, Liguria e Molise, che quindi risultano essere le regioni più simili fra loro rispetto alle 7 produzioni considerate. Al contrario, Sicilia, Puglia e Calabria sono le ultime regioni ad aggregarsi: ciò significa che queste presentano valori atipici rispetto alle produzioni analizzate e perciò rimangono singletons fino agli ultimi livelli della gerarchia.

Applicando una cluster analysis non gerarchica con il metodo delle k medie per 4 gruppi, si ottengono risultati simili all'analisi gerarchica, in quanto entrambi questi metodi sfruttano la minimizzazione della variabilità interna al gruppo come misura di bontà: la partizione in 4 gruppi risulta ottimale, spiegando il 79.5% della variabilità totale e presentando un indice ccc superiore a 2 (12.67).

Cluster=1				Cluster=3			
Variabile	N	Media	Coeff di variazione	Variabile	N	Media	Coeff di variazione
uvatavol	1	97.0000000	.	uvatavol	1	6031.00	.
uvavino	1	1276.00	.	uvavino	1	8738.00	.
vinoprod	1	894.0000000	.	vinoprod	1	6824.00	.
arance	1	5274.00	.	arance	1	307.0000000	.
mandarin	1	549.0000000	.	mandarin	1	97.0000000	.
clementine	1	1460.00	.	clementine	1	167.0000000	.
limoni	1	309.0000000	.	limoni	1	24.0000000	.

Cluster=2				Cluster=4			
Variabile	N	Media	Coeff di variazione	Variabile	N	Media	Coeff di variazione
uvatavol	17	111.4117647	253.6474851	uvatavol	1	2774.00	.
uvavino	17	3148.76	102.0757337	uvavino	1	10004.00	.
vinoprod	17	2323.18	104.5740735	vinoprod	1	7715.00	.
arance	17	84.4705882	218.2828741	arance	1	11468.00	.
mandarin	17	21.1176471	254.7487207	mandarin	1	1082.00	.
clementine	17	17.5882353	256.0427575	clementine	1	667.0000000	.
limoni	17	26.8823529	354.0539976	limoni	1	5844.00	.

La partizione in 4 gruppi derivante dall'analisi non gerarchica è composta da 3 singletones (Calabria, Puglia e Sicilia) e un cluster comprendente le restanti 17 regioni. Il secondo gruppo è caratterizzato da produzione vinicola superiore alla produzione media e da produzioni di agrumi e di uva da tavola inferiori alla produzione media. Le tre singole regioni invece presentano valori delle produzioni profondamente diversi da quelli delle altre regioni, come emerso anche dall'analisi univariata iniziale, e perciò rimangono isolate. In particolare, la Calabria (cluster 1) presenta produzioni di arance, mandarini e clementine notevolmente superiori alle produzioni medie, la Puglia (cluster 2) si contraddistingue per la raccolta di uva da tavola pari a 6031 migliaia di quintali, superando considerevolmente la produzione media nazionale, e infine la Sicilia (cluster 3) è caratterizzata da produzioni di agrumi fortemente maggiori delle produzioni medie relative a tutte le regioni italiane.